BIRD Mini-Dev

数据库模式扰动验证性实验报告

向量检索桥接成分漏选与小模型鲁棒性评估

报告版本：最新实验结果（2026-10-26）

数据集：BIRD Mini-Dev，500 条问题，11 个数据库

模型：Qwen3 0.6B / 1.7B / 4B，Qwen2.5-Coder 1.5B，DeepSeek API 对照

实验规模：5,097 个问题变体；question-only 向量检索；SQLite 执行评分

总体判定：检索假设成立；执行门槛未通过

本报告按本次服务器归档重新整理，旧版 PDF（2026-10-23）不作为本次结果依据。

1. 摘要

本实验在 BIRD Mini-Dev 的 500 条问题上构造两类模式扰动：向问题对应 schema 中加入无关列（随机列、同名/近义列），以及删除多表问题的桥接表或外键列。实验同时评估向量检索是否漏掉连接所需 schema 成分，并比较四个本地小模型与 DeepSeek API 对照在扰动下的执行准确率。

主要结论

（1）检索侧证据支持研究假设：k=10 时，外键/关键连接列漏选率 57.85%，比单表目标列 28.71% 高 29.14 个百分点（95% CI [+21.49,+36.84]）；桥接表内列高 12.89 个百分点。

（2）执行侧预注册门槛未通过：add_synonym_20 下，小模型相对 API 的准确率下降差为 −32.0、−25.4、−9.0、−28.2 个百分点；add_random_20 下为 −1.8、−1.2、+0.6、−3.8 个百分点，均未达到“至少高 10 个百分点”。

（3）因此本轮实验支持“连接成分更容易被检索漏选”，但不支持“小模型在 20 列扰动下比 API 多掉 10 个百分点”。

2. 研究问题与判定标准

RQ1（检索）：多表问题中的桥接表、桥接表列和外键列，是否比单表目标列更容易在 top-k 检索中漏选？主分析 k=10，要求差值 95% CI 下界大于 0 且单侧 $p<0.05$。

RQ2（执行）：加入 20 个无关列后，小模型执行准确率下降是否比 API 对照多至少 10 个百分点？分别考察随机列和同名/近义列，使用 500 条问题的配对门槛统计。

3. 实验设计

3.1 数据与扰动

项目	数量/设置	说明
原始问题	500	86 条单表；414 条多表；396 条有连接关系
数据库	11	BIRD Mini-Dev 官方 dev 数据库
多给列	4,000	random 5/10/20/50 与 synonym 5/10/20/50，各 500 条
漏给 schema	597	missing_bridge_table 103；missing_fk_column 494
总变体	5,097	含 base 500 条

3.2 模型与评分

本地模型：Qwen3 0.6B、Qwen3 1.7B、Qwen3 4B、Qwen2.5-Coder 1.5B；API 对照：DeepSeek Chat（deepseek-chat）。本地模型使用贪心解码；每条预测在对应 SQLite 数据库执行，30 秒超时视为不可评分。检索使用 all-MiniLM-L6-v2、question-only 文本，统计 top-k=5/10/20/50；bootstrap 10,000 次，按问题聚类。

3.3 可复现文件

/Users/xiaotao/PycharmProjects/DataAgentSystem/BIRD_MINIDEV_VALIDATION_20261025_server；关键文件：model_eval/execution_gate.json、retrieval/output/retrieval_report_question.md、deliverables/曲线图。

4. 检索结果

指标（漏选率）	k=5	k=10	k=20	k=50
单表目标列	41.63%	28.71%	17.22%	8.61%
桥接表（表级）	38.83%	16.50%	1.94%	0.00%
桥接表内列	67.60%	41.60%	22.80%	6.00%
外键/关键连接列	74.77%	57.85%	39.69%	17.13%
桥接成分并集	73.93%	56.88%	38.95%	16.57%

在主分析 k=10 下，桥接表内列相对单表目标列高 12.89 pp（95% CI [+2.21,+23.45]，p=0.0100）；外键列高 29.14 pp（95% CI [+21.49,+36.84]，p=0.0001）；并集高 28.17 pp（95% CI [+20.58,+35.65]，p=0.0001）。

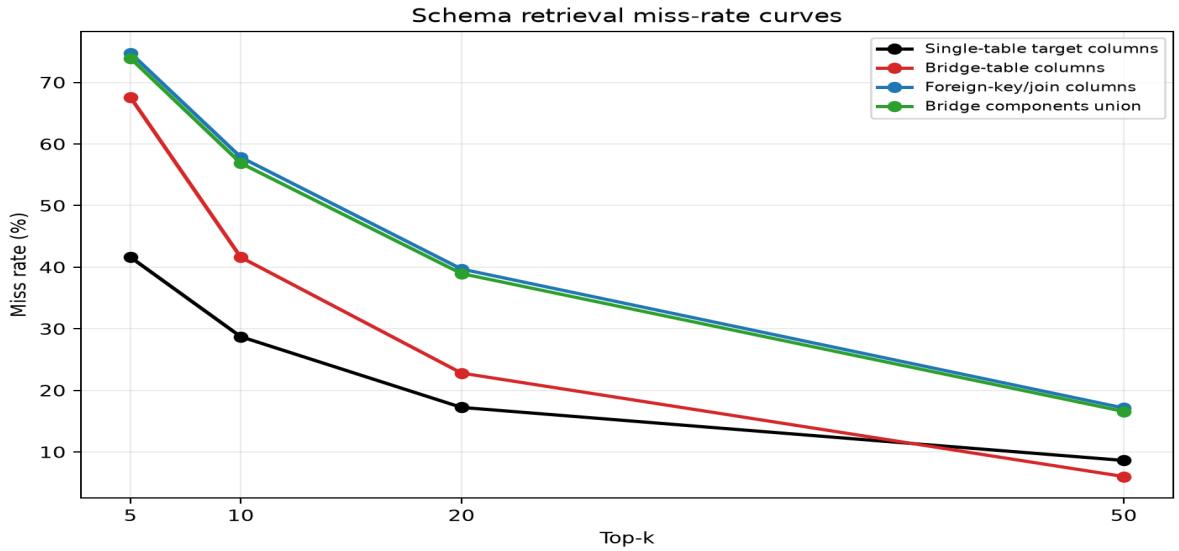


图 1 不同 top-k 下的 schema 成分漏选率

5. 执行结果与门槛判定

下表使用预注册门槛的配对 500 条分母；“相对 API 差”=小模型准确率下降 − API 准确率下降。

模型	base	random20	下降	synonym20	下降	相对 API
DeepSeek API	68.6%	62.2%	6.4 pp	27.4%	41.2 pp	—
Qwen3 0.6B	14.6%	10.0%	4.6 pp	5.4%	9.2 pp	−1.8 / −32.0 pp
Qwen3 1.7B	27.0%	21.8%	5.2 pp	11.2%	15.8 pp	−1.2 / −25.4 pp
Qwen3 4B	50.6%	43.6%	7.0 pp	18.4%	32.2 pp	+0.6 / −9.0 pp
Qwen2.5-Coder 1.5B	26.8%	24.2%	2.6 pp	13.8%	13.0 pp	−3.8 / −28.2 pp

门槛结论：未通过。 随机 20 列下相对 API 差值范围为 −3.8 到 +0.6 pp；同名/近义 20 列下范围为 −32.0 到 −9.0 pp。API 在 synonym20 上下降 41.2 pp，反而比所有本地模型下降更多。

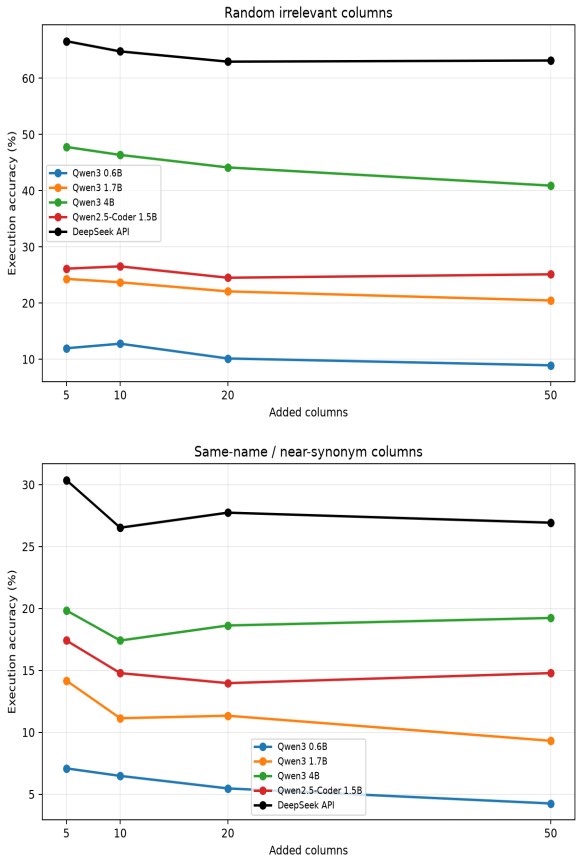


图 2—3 随机列与同名/近义列扰动下执行准确率

6. 漏给 schema 的补充结果

模型	删除桥接表	删除外键列
DeepSeek API	18.18%（18/99）	36.36%（176/484）
Qwen3 0.6B	0.00%（0/99）	1.45%（7/484）
Qwen3 1.7B	2.02%（2/99）	7.23%（35/484）
Qwen3 4B	3.03%（3/99）	21.07%（102/484）
Qwen2.5-Coder 1.5B	3.03%（3/99）	9.30%（45/484）

本表来自可评分汇总分母；当前 scorer 有 6 个 gold SQL 在 30 秒内未完成（question id 116、129、145、159、518、701），因此与上一页的 paired-500 门槛表不直接混用。

7. 讨论、局限与下一步

结果更支持“连接 schema 成分是检索瓶颈”，尤其是外键列；这为桥接表优先召回、外键增强和结构化 rerank 提供依据。执行门槛失败的主要原因不是小模型独有的随机列脆弱性，而是 API 在同名/近义列干扰下也显著退化。下一步应把列名语义歧义与 schema 结构缺失拆开做交叉实验。当前结论基于单一数据集、单一 embedding、一次贪心推理；尚未证明跨数据集或跨检索器的普适性。

8. 最终结论

本次 BIRD Mini-Dev 验证性实验完成了数据扰动、向量检索统计、四个本地模型和 API 对照的执行评分。检索假设得到统计支持：多表连接所需的桥接列与外键列确实更容易在 top-k schema 检索中漏选。执行假设未得到支持：在 20 个无关列条件下，小模型相对 API 的准确率下降没有达到预设的 10 个百分点优势，近义列条件下甚至是 API 下降更大。

给老师的简短结论：“本轮实验完成且结果可复现；RQ1（连接成分漏检）成立，RQ2（小模型在 20 列扰动下显著更脆弱）不成立。后续将把重点放在结构感知 schema 检索和列名歧义控制实验上。”

报告生成日期：2026-10-26 | 结果归档：BIRD_MINIDEV_VALIDATION_20261025_server