小模型 Schema 鲁棒性与向量检索外键偏差（两页版）

BIRD Mini-Dev SQLite， 500 题， 11 库；Qwen3-0.6B/1.7B/4B 、 Qwen2.5-Coder-1.5B 、DeepSeek

结论先行

- **检索偏差是外键/连接列，不是桥接表**：控制多表题后，外键/连接列比普通目标列 更难召回 +13.75pp（95% CI [+9.79, +17.73]），桥接表内列反而不更难（−13.91pp）。
- **加入 20 个真实无关列的主门槛不通过**：四个小模型相对 DeepSeek 的额外下降为 0.00 到 +5.10pp，均低于预注册的 10pp。
- **条件效应存在**：在双方基线都可解的题上，小模型保持率显著更低 （+16.5 到 +51.9pp）。

实验设计

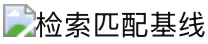
条件	说明	题数
base	仅 gold 表与列	500
多给 20 列·任意表	20 个全库真实无关列	431
多给 20 列·仅 gold 表	20 个 gold 表内真实无关列	224
漏给	移除桥接表 / 外键列	103 / 494

评分用 BIRD 官方集合语义 + 30 秒超时；检索用 MiniLM 向量化，k=10，问题级配对 bootstrap。

检索结果

类别	漏选率
单表目标列	28.71%
多表非桥接目标列	47.45%
桥接表内列	41.60%
外键/连接列	57.85%

外键/连接列显著更难召回（+13.75pp），桥接表本身不构成额外偏差。

 检索匹配基线

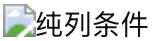
执行结果

模型	base	任意表	仅gold表
DeepSeek	68.6%	67.1%	56.7%
Qwen3-0.6B	14.8%	12.1%	7.6%
Qwen3-1.7B	27.6%	23.7%	15.6%
Qwen3-4B	50.4%	42.5%	37.1%

模型	base	任意表	仅gold表
Qwen2.5-Coder-1.5B	26.4%	20.9%	18.3%

相对 DeepSeek 的额外下降：任意表 +0.46/+2.09/+5.10/+3.25pp；仅 gold 表 0.00/+1.34/+0.89/−1.79pp。四模型均未达到 +10pp。

模型	基线可解子集·额外失败	95% CI
Qwen3-0.6B	+28.33pp	[+16.67, +41.67]
Qwen3-1.7B	+29.82pp	[+21.05, +38.60]
Qwen3-4B	+16.50pp	[+11.00, +22.50]
Qwen2.5-Coder-1.5B	+37.50pp	[+26.92, +48.08]

 纯列条件

漏给结果

移除桥接表或外键列后，严格合规准确率都很低（1.26%—11.11%）；DeepSeek 的普通执行优势 主要来自读取或猜中被隐藏的连接列。

一句话

原「小模型总体比大模型多下降 10pp」的假设未获支持；但检索外键偏差与「基线可解子集上的 条件效应」都稳定存在，说明研究重心应转向外键检索与条件鲁棒性，而不是无关列数量本身。

下一步

Spider 2.0-Lite SQLite 复验，主指标改为「基线可解子集上的保持率差」，先做功效分析； Qwen3-0.6B 是否进入确认性门槛作为独立决策。