小模型 Schema 鲁棒性与向量检索外键偏差

BIRD Mini-Dev 验证性实验报告

日期：2026-10-23
数据：BIRD Mini-Dev SQLite（500 题，11 个数据库）
模型：Qwen3-0.6B / 1.7B / 4B、Qwen2.5-Coder-1.5B、DeepSeek deepseek-chat

摘要

本文在 BIRD Mini-Dev 的 500 个问题上，考察本地小模型与 API 大模型在 schema 扰动下的执行鲁棒性差异，并检验向量检索是否系统性漏掉多表问题中的连接成分。结果表明：

1. 向量检索对外键/连接列的漏选率显著高于普通目标列（+13.75pp，95% CI [+9.79, +17.73]）。
2. 加入 20 个真实无关列后，四个小模型相对大模型的执行准确率下降均未达到预注册的 10pp 门槛，效应接近零。
3. 在双方基线均可解的子集上，小模型的保持率显著更低（+16.5 到 +51.9pp）。

总体而言，「小模型总体上比大模型多下降 10pp」的操作化假设未获支持；但检索外键偏差与条件效应为后续研究提供了明确方向。

1 研究问题与假设

- RQ1：加入无关列后，小模型执行准确率是否比大模型下降更多?
- RQ2：向量检索是否更容易漏掉多表问题中的外键/连接列?

预注册门槛：

- H1（检索）：外键/连接列的漏选率显著高于普通目标列（配对 95% CI 下界大于 0）。
- H2（执行）：小模型在加入 20 个无关列时的执行准确率下降，比大模型至少多 10 个百分点。

2 实验设计

2.1 数据

BIRD Mini-Dev SQLite，500 个 question_id，11 个数据库。难度分布：simple 148、moderate 250、challenging 102。基线 schema 由 gold SQL 经 sqlglot 解析得到，仅保留 gold SQL 实际引用的表与列；500 条基线均通过 schema qualification。

2.2 模型

模型	角色	参数
Qwen3-0.6B	小模型	0.6B
Qwen3-1.7B	小模型	1.7B
Qwen3-4B	小模型	4B
Qwen2.5-Coder-1.5B-Instruct	小模型	1.5B

模型	角色	参数
DeepSeek deepseek-chat	大模型对照	—

所有模型使用相同 prompt 与最大输出长度；小模型用贪心解码，大模型 temperature=0。

2.3 条件

条件	说明	题数
base	仅 gold 表与列	500
多给 20 列·任意表	加入 20 个全库范围内的真实无关列	431
多给 20 列·仅 gold 表	加入 20 个 gold 表内的真实无关列，不新增表	224
漏给·桥接表	从 schema 移除桥接表	103
漏给·外键列	从 schema 移除关键外键/连接列	494

多给条件只使用真实列，不使用合成列；候选不足 20 的题目直接排除并记录。漏给条件仅从 prompt 的 schema 移除表或列，物理数据库保持不变。

2.4 评分

预测 SQL 与 gold SQL 均在只读 SQLite 连接中执行，采用 BIRD 官方集合语义 `set(predicted_rows) == set(gold_rows)`，30 秒超时；执行错误按 incorrect 计。

2.5 向量检索

使用 sentence-transformers/all-MiniLM-L6-v2 对列做向量化，查询为 question-only，主分析 k=10。为控制题目类型混淆，引入「多表非桥接目标列」基线（多表题中既非桥接表列、也非连接列的目标列），并做问题级配对 bootstrap（10000 次）。

3 结果

3.1 检索（H1）

类别	漏选率
单表目标列	28.71%
多表非桥接目标列	47.45%
桥接表内列	41.60%
外键/连接列	57.85%

配对差值（k=10）：

比较	差值	95% CI	判定
外键/连接列 − 多表非桥接目标列	+13.75pp	[+9.79, +17.73]	显著
桥接表内列 − 多表非桥接目标列	−13.91pp	[−24.22, −3.69]	不更难

H1 成立，但偏差集中在外键/连接列，而非桥接表本身。

3.2 执行准确率（H2）

模型	base	多给20列·任意表	多给20列·仅gold表
DeepSeek deepseek-chat	68.6%	67.1%	56.7%
Qwen3-0.6B	14.8%	12.1%	7.6%
Qwen3-1.7B	27.6%	23.7%	15.6%
Qwen3-4B	50.4%	42.5%	37.1%
Qwen2.5-Coder-1.5B	26.4%	20.9%	18.3%

小模型相对 DeepSeek 的额外下降：

模型	任意表（n=431）	仅gold表（n=224）
Qwen3-0.6B	+0.46pp	0.00pp
Qwen3-1.7B	+2.09pp	+1.34pp
Qwen3-4B	+5.10pp	+0.89pp
Qwen2.5-Coder-1.5B	+3.25pp	−1.79pp

四个小模型在两种条件下的额外下降均低于 10pp，绝大多数接近 0。H2 不成立。

3.3 条件效应（基线可解子集）

在双方基线均可解的题上，统计扰动后的保持率（任意表条件）：

模型	共同正确题数	额外失败	95% CI
Qwen3-0.6B	60	+28.33pp	[+16.67, +41.67]
Qwen3-1.7B	114	+29.82pp	[+21.05, +38.60]
Qwen3-4B	200	+16.50pp	[+11.00, +22.50]
Qwen2.5-Coder-1.5B	104	+37.50pp	[+26.92, +48.08]

小模型对 schema 干扰的额外敏感集中体现在「原本会做」的题上；由于小模型基线准确率较低（地板效应），该效应没有转化为总体 10pp 的下降差。

3.4 漏给

模型	桥接·普通	桥接·合规	外键·普通	外键·合规
DeepSeek deepseek-chat	19.42%	11.11%	35.02%	2.47%
Qwen3-0.6B	0.00%	0.00%	1.62%	2.50%
Qwen3-1.7B	2.91%	11.11%	7.49%	3.82%
Qwen3-4B	2.91%	5.66%	20.24%	2.41%
Qwen2.5-Coder-1.5B	1.94%	9.09%	10.12%	1.26%

「普通」为执行准确率；「合规」为预测 SQL 不使用被移除表/列的比例。移除连接成分后，所有模型的严格合规准确率都很低，大模型的普通执行优势主要来自读取或猜中被隐藏的连接列。

4 讨论

- 检索偏差集中在语义信息较弱的外键/连接列（`id`、`*_id`），与「连接键在向量空间中缺乏语义」的解释一致；桥接表名通常有辨识度，因此并不更难召回。
- 全体准确率门槛受地板效应影响：小模型基线准确率低，绝对下降空间有限，因此「相对大模型多下降 10pp」这一全体门槛较难满足。
- 条件分析显示，在基线可解的题上小模型保持率显著更低，说明小模型确实对 schema 干扰更敏感，只是这一效应被总体门槛的构造方式掩盖。
- 漏给结果支持「连接 schema 成分缺失会造成严重退化」，但不支持「大模型能在完全不使用缺失成分时稳定恢复」。

5 结论

- H1 成立：向量检索对外键/连接列存在稳健漏选偏差（+13.75pp）。
- H2 不成立：小模型加入 20 个真实无关列后，总体执行下降未比大模型多 10pp。
- 条件效应存在：在基线可解的题上，小模型保持率显著更低（+16.5 到 +51.9pp）。
- 下一步：在 Spider 2.0-Lite SQLite 上复验，以「基线可解子集上的保持率差」为主指标，并先做功效分析。

6 局限

维度	局限
推理方差	单次贪心解码，无多种子重跑；CI 只覆盖题目间方差
外部效度	单个 Mini-Dev 数据集、单个 MiniLM 检索器、单一 DeepSeek 快照
地板效应	小模型基线准确率低，总体下降空间受限
API 可复现性	DeepSeek 温度 0 仍存在约 0.4pp 的运行间波动