BIRD Mini-Dev 7–8 周验证性实验

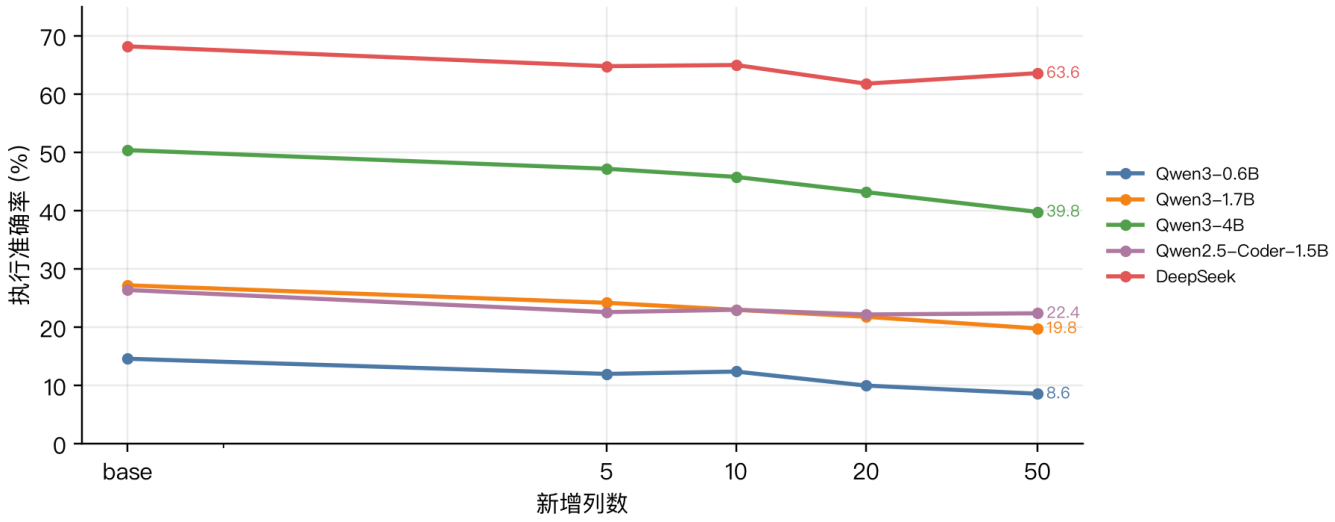
小模型 Schema 鲁棒性与外键检索偏差 · 两页版 v2

数据：BIRD Mini-Dev SQLite，500 题，11 库 · 模型：Qwen3-0.6B/1.7B/4B、Qwen2.5-Coder-1.5B、DeepSeek deepseek-chat · 2026-10-22

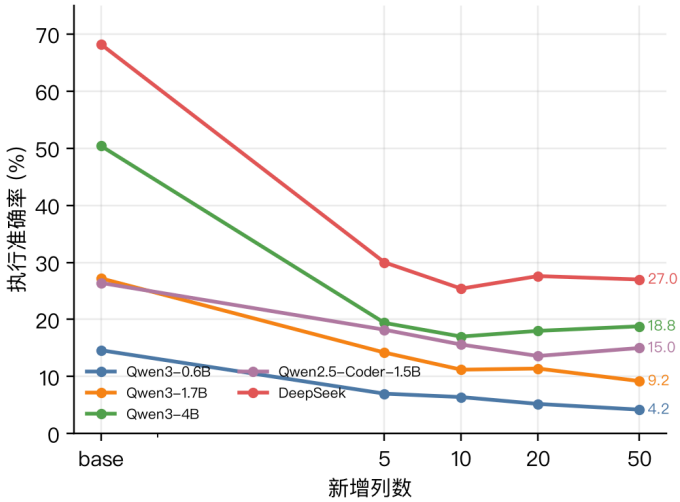
结论先行

- **原预注册 10pp 全体门槛不通过**：随机 20 列下降差 −2.20 到 +0.80pp，95% CI 上界最高 +5.2pp；数据可排除“小模型多下降 10pp”。
- **纯列 20 补实验仍不通过全体门槛**：下降差 +0.60/+4.60/+1.80/−3.80pp，CI 上界均 <10pp；但 baseline-correct 额外失败仍为 +10.00 到 +34.13pp。
- **检索偏差是外键/join 列，不是桥接表**：控制多表题后，桥接表内列 −13.91pp，外键/join 列 +13.75pp。

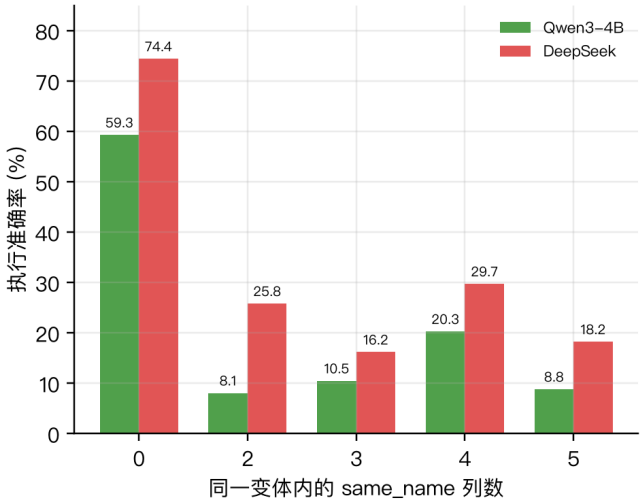
随机加列：总体影响温和，但该条件同时引入了新表

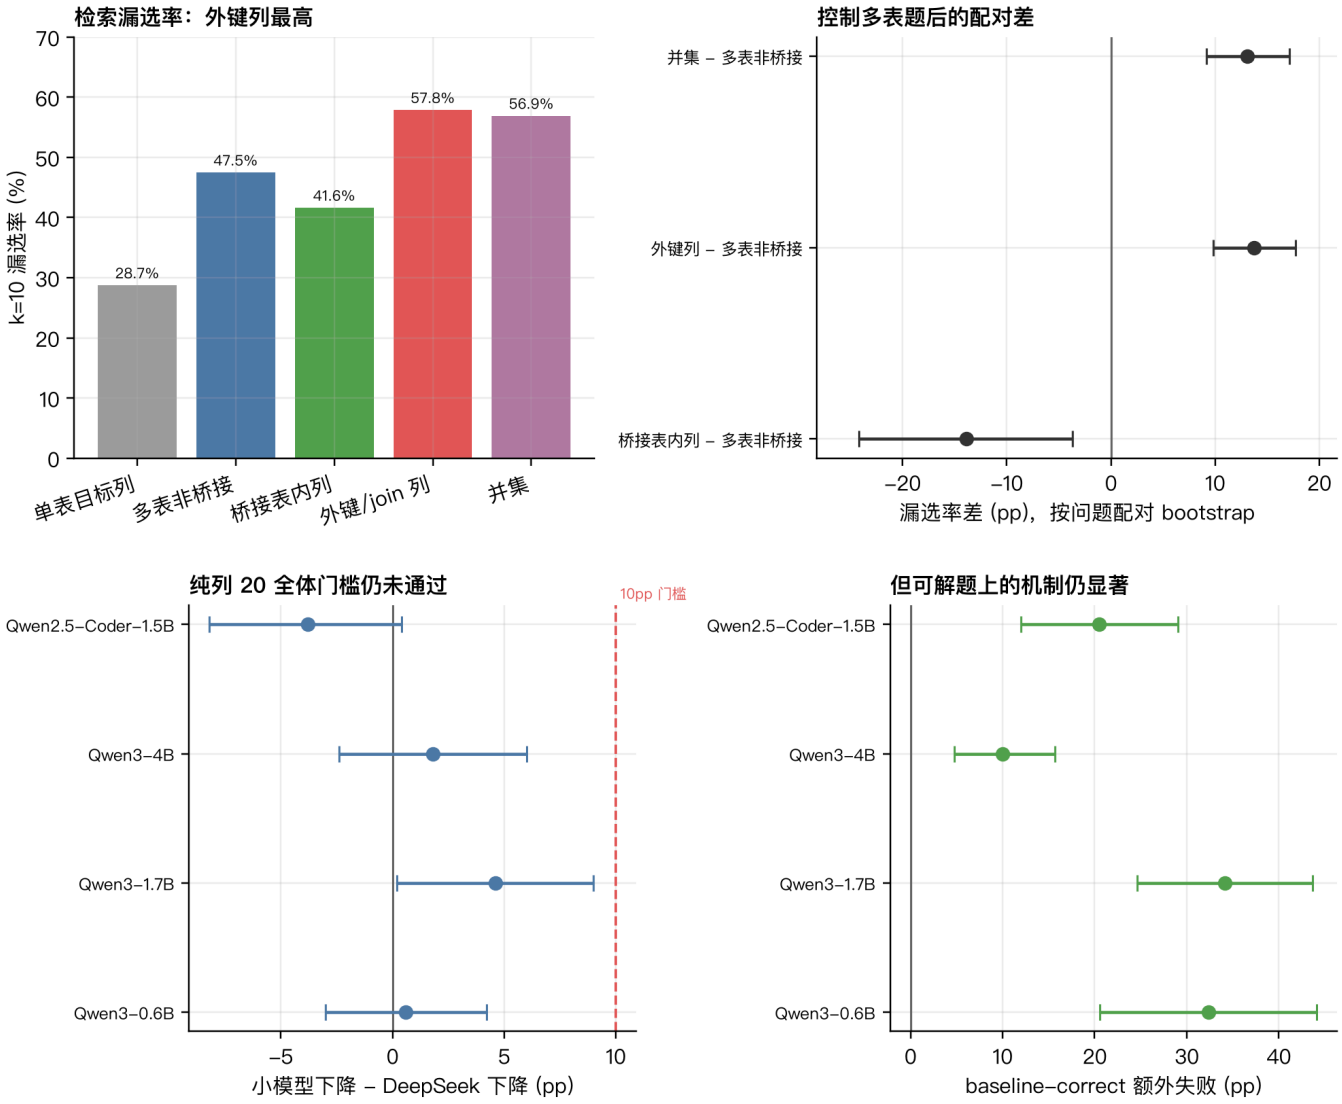


同名/近义加列：5 列即出现断崖



5 列条件内部：同名干扰驱动断崖





需要修正的三点

- 原 add_random_* 同时引入新表：20 列时 494/500 个变体至少新增一张表，58.9% 的新增列来自新表；它不能回答“只加无关列”的问题。
- 原 add_synonym_5 中 63.5% 是 same_name；5 列断崖主要来自同名干扰，不是纯词法近义。
- 真实近义列 423/427 题也引入新表，只有 4 题是 gold-only；不能把 41.22pp→6.32pp 全归因于“真实 vs 合成”。

请导师决定

方案	做法	评价
A 50 题 pilot	官方可见的 50 题，base + 20 列	可立即做，但功效不足：0.6B 共同正确约 5 题
B 补 85 条 gold SQL	到 135 题，重跑确认性实验	最接近原计划；0.6B 仍可能不足 30 题
C 表级 135 题	用 gold tables 全部列当 baseline	不需要缺失 SQL，但研究变量变成表级
D 收缩 RQ1	以 BIRD + 可用 Spider 结果做系统实证	风险最低，符合任务书兜底

建议：A 先做 pilot + 向作者申请剩余 gold SQL；确认性主指标改为 baseline-correct，并把 0.6B 是否退出 gate 作为独立决策。若 RQ3 要立住，需再补 retrieved-schema 执行条件（约 2,500 条预测）。

一句话：原假设没有被确认，但失败原因已经定位：不是“无关列数量”，而是**外键检索、同名干扰和 baseline 条件效应**。下一步应换主指标、补样本量，而不是继续在原 10pp 门槛上加解释。

详细版：result/BIRD_MiniDev_Experiment_Report_v2.md / POSTHOC_REANALYSIS_2026-10-22.md；服务器结果：7-8周/BIRD_RESULTS/