BIRD Mini-Dev 验证性实验报告（v2）

小模型 Schema 鲁棒性与向量检索外键偏差

原始实验日期：2026-10-21
事后重分析与纯列补实验：2026-10-22
数据规模：BIRD Mini-Dev SQLite，500 道题，11 个数据库
实验定位：探索性验证、事后重分析与下一阶段确认性实验设计

版本说明

v1 报告记录了原始预注册门槛和正式评分。v2 不改变 v1 的历史判定， 而是把 2026-10-22 的事后审计与纯列补实验整合进正文：

1. 原“桥接成分”检索结论收窄为“外键/join 列偏差”；
2. 说明原 `add_random_*` 同时引入了新表， `add_synonym_*` 的 5 列断崖 主要由 `same_name` 造成；
3. 补充“只加列、不加表”的纯列 20 实验；
4. 修正缺失 schema 的合规分母与 evidence 泄漏问题；
5. 保留原预注册门槛“不通过”的判定，不把事后分析写成确认性结果。

执行摘要

本实验在 BIRD Mini-Dev 的 500 道题上，以 gold SQL 所需的表和列为基线， 考察四个本地小模型与一个 API 大模型在 schema 多给、漏给和检索条件下的 鲁棒性。

核心结论：

- **检索预注册门槛通过，但结论必须收窄。** 原始 k=10 的“桥接成分并集” 漏选率为 56.88%，比单表目标列高 28.17pp。加入“多表题非桥接目标列” 基线后，桥接表内列反而低 13.91pp（95% CI [−24.22, −3.69]）， 只有外键/join 列高 13.75pp（95% CI [+9.79, +17.73]） 。 因此真正的检索偏差是**外键/连接列**，不是桥接表本身。
- **原预注册执行门槛不通过。** 随机加 20 列时，四个小模型相对 DeepSeek 的下降差为 −2.20 到 +0.80pp，95% CI 上界最高 +5.2pp； 数据可以排除“小模型多下降 10pp”的效应。
- **baseline-correct 分析支持机制，但属于事后条件分析。** 在双方 base 都正确的题上，小模型在随机列条件下的额外失败为 25.98−34.48pp， 真实 schema 近义列下为 17.35−30.63pp。
- **纯列 20 补实验仍不通过全体门槛，但机制保留。** 只加列、不加表时， 四个下降差为 +0.60/+4.60/+1.80/−3.80pp，CI 上界均 <10pp； 但 baseline-correct 额外失败仍为 +10.00 到 +34.13pp。
- **5 列近义断崖主要由同名干扰造成。** `same_name=0` 时 Qwen3-4B/ DeepSeek 为 59.30%/74.42%；出现 2 个以上同名干扰后降到 8−20%。
- **漏给实验的普通准确率会高估合规恢复能力。** DeepSeek 外键正确预测中 162/173 仍读取被移除列；合规分母是 authorizer 成功子集（9/81、11/446）， 不是全部变体或 base-correct。
- **最终判定不变：** BIRD 结果不足以确认原操作化假设；进入 Spider 2.0-Lite 时应以预先固定的 baseline-correct 为主指标，并先做功效分析。

1 研究问题与假设

- RQ1：加入无关列后，小模型执行准确率是否比 API 大模型下降更多?
- RQ2：向量检索是否更容易漏掉多表问题中的桥接表和外键/连接列?
- RQ3：检索偏差与模型执行退化是否共同指向 schema linking 是主要失败环节?

原预注册假设：小模型在加入 20 个无关列时的执行准确率下降，比 API 大模型 至少多 10 个百分点；同时，向量检索对桥接成分的漏选率显著高于单表目标列。 两个条件必须同时成立。

v2 的澄清：

- RQ1 的原操作化指标（全体准确率下降差 ≥10pp）未通过；机制证据来自 baseline-correct 条件分析，不能替代原门槛。
- RQ2 的“桥接成分”需拆成桥接表内列与外键/join 列；控制多表题后， 只有后者稳健。
- RQ3 仍未被原实验识别：原执行实验使用 oracle gold schema，检索偏差是 独立测量；若要检验因果链，需要额外的 retrieved-schema 执行条件。

2 数据与模型

2.1 BIRD Mini-Dev

数据包含 500 个唯一 question_id、11 个 SQLite 数据库。

数据库	题数
california_schools	30
card_games	52
codebase_community	49
debit_card_specializing	30
european_football_2	51
financial	32
formula_1	66
student_club	48
superhero	52
thrombosis_prediction	50
toxicology	40

难度	题数
simple	148
moderate	250
challenging	102

2.2 模型

模型	角色	运行方式
Qwen3-0.6B	本地小模型	BF16/FP16，非 thinking

模型	角色	运行方式
Qwen3-1.7B	本地小模型	BF16/FP16，非 thinking
Qwen3-4B	本地小模型	BF16/FP16，非 thinking
Qwen2.5-Coder-1.5B-Instruct	本地代码模型	贪心解码
DeepSeek deepseek-chat	API 对照	temperature=0

五类模型使用相同 prompt、schema 条件和最大输出 token 数。主实验共完成 5 × 9 × 500 = 22,500 条预测，另完成 5 × 427 = 2,135 条真实 schema 近义列预测、5 × 597 = 2,985 条漏给预测，以及 5 × 1,000 = 5,000 条纯列 20 补实验预测（base + pure 20）。

3 实验设计

3.1 基线 Schema

使用 sqlglot 解析 gold SQL，提取真实表、显式列、连接边和 join 键。基线 schema 仅保留 gold SQL 所需的表与列。500 条基线均通过 schema qualification。

3.2 多给列扰动（v1）

构造 add_random_5/10/20/50 和 add_synonym_5/10/20/50 共八个条件， 每个条件严格 500 条。

- 随机列从全库未被 gold SQL 使用的列中采样。由于基线只含 gold tables， 这会同时引入新表：`add_random_20` 有 494/500 个变体至少新增一张表， 58.9% 的新增列来自新表；`add_random_5` 为 467/500、63.8%。
- 候选不足时补充中性合成列并标记 `generated=true`。`add_random_50` 的 25,000 个新增列中有 4,387 个（17.5%）是合成列，并非“极少数”。
- 同名/近义列包含其他 base tables 的同名列和基于列名词法生成的近义列。 `add_synonym_5` 的 2,500 个新增列中 1,588 个（63.5%）是 `same_name`； 10 列为 39.9%，20 列为 21.7%，50 列为 8.7%。
- 所有新增列只改变模型看到的 schema 元数据，不物理修改 SQLite 数据库。

3.3 纯列补实验（v2）

为了隔离“列数”本身，新增 `add_pure_column` 条件：

- 所有新增列都属于 gold tables，**不新增任何表**；
- 20 列条件中 66.9% 是真实列，33.1% 是中性 filler；10 列为 82.6% 真实列， 5 列为 90.0% 真实列；
- 五模型各完成 base + pure 20 共 1,000 条预测；
- 该条件不替代原 `add_random_*`，而是回答“只加列、不加表会怎样”。

3.4 漏给扰动

在 gold join 图上识别桥接表，并优先删除显式外键侧；没有声明外键时，回退到 关键 join 列并标记 `declared_foreign_key=false`。共生成 missing_bridge_table 103 条、missing_fk_column 494 条。

扰动只从 prompt 的 schema 中移除表和列，SQLite 物理数据库保持不变。 除普通执行准确率外，还使用 SQLite authorizer 在 EXPLAIN 编译阶段记录预测 实际读取的物理表和列。

3.5 执行评分

预测 SQL 与 gold SQL 均在只读 SQLite 连接中执行。正式评分严格采用 BIRD Mini-Dev 官方 evaluation_ex.py 的集合语义： `set(predicted_rows) == set(gold_rows)`，忽略行顺序和重复行。 模型 SQL 与 gold SQL 均使用官方默认 30 秒超时；执行错误按 incorrect 记录。

3.6 向量检索

使用 sentence-transformers/all-MiniLM-L6-v2。列文档包含表名、列名、类型和 主键标记；主分析使用 question-only，k=10，并报告 k=5/10/20/50。另报告 question+evidence 作为敏感性分析。

原始比较基线是单表题目标列。v2 增加： `multi_nonbridge` = 多表题 gold 列中既不属于桥接表、也不属于 join/FK 的列。 该基线用于控制“单表题 vs 多表题”的题目类型混淆。

4 数据审计

原始扰动文件共 5,097 条唯一 variant_id；base 与八个多给条件均为 500 条。 服务器文件 SHA-256 为 `b1271267ebb3dcd4af584127422108f9eec304cbfd9ce150f998bbc04eb364e5`。

并发运行期间，Qwen3-0.6B、DeepSeek 以及 v2 的 1.7B/4B 曾出现重复写入； 正式分析前均按 variant_id 去重。纯列 20 补实验的预测文件最终均为 1,000 条 唯一记录。

独立 gold 审计中，500 条 gold SQL 有 498 条在 30 秒内完成，2 条超时。 正式结果已使用官方集合语义重新评分全部 27,620 条 v1 预测；v2 纯列预测 另用同一官方 scorer 评分。

5 检索实验结果

5.1 原始预注册结果

主实验使用 question-only 检索，k=10。桥接表采用“表内任意一列进入 top-k 即命中”的表级口径；外键列、桥接表内列和单表目标列采用列级口径。

指标	漏选数	总数	漏选率
单表目标列	60	209	28.71%
桥接表（表级）	17	103	16.50%
桥接表内列	104	250	41.60%
外键/关键连接列	564	975	57.85%
桥接成分并集	587	1032	56.88%

原报告的比较对象是单表目标列，因此“桥接成分并集 +28.17pp”同时包含了 多表题难度和列类型效应。

5.2 匹配基线（v2）

使用原脚本的文档构造与标签集合复算，绝对漏选率与 v1 完全一致。加入 `multi_nonbridge` 后，k=10：

类别	漏选率
单表目标列	28.71%
多表题非桥接目标列	47.45%
桥接表内列	41.60%
外键/join 列	57.85%
桥接成分并集	56.88%

按问题配对的 bootstrap：

比较	差值	95% CI
桥接表内列 − 多表非桥接目标列	−13.91 pp	[−24.22, −3.69] pp
外键列 − 多表非桥接目标列	+13.75 pp	[+9.79, +17.73] pp
桥接成分并集 − 多表非桥接目标列	+13.11 pp	[+9.16, +17.14] pp

结论：控制多表题后，桥接表内列并不更难召回；显著更难的只有外键/join 列。 原 +28.17pp 主要是题目类型效应，不能解释为“桥接表偏差”。

5.3 question+evidence 敏感性

类别	漏选率
单表目标列	20.57%
多表题非桥接目标列	37.34%
桥接表内列	43.60%
外键/join 列	58.97%
桥接成分并集	57.66%

配对差值：桥接表内列 +2.15pp（95% CI [−7.96, +12.24]）， 外键列 +26.11pp（95% CI [+22.15, +30.16]）。桥接表效应不稳健， 外键/join 效应在两种 query 下都稳健。

5.4 检索结论

检索预注册门槛按原指标仍为“通过”，但机制结论应改写为： **向量检索对外键/join 列的漏选偏差显著；对桥接表本身的偏差不稳健。** 这比“桥接成分偏差”更精确，也更能指导 schema linking 的改进。

6 执行准确率结果

以下曲线使用各模型在每个扰动条件下的共同可评测题目。v1 的完整列级曲线 保存在 `BIRD_RESULTS/analysis/column_level_curves_official.csv`。

6.1 随机列

模型	base	5 列	10 列	20 列	50 列
Qwen3-0.6B	14.60%	12.00%	12.40%	10.00%	8.60%

模型	base	5 列	10 列	20 列	50 列
Qwen3-1.7B	27.20%	24.20%	23.00%	21.80%	19.80%
Qwen3-4B	50.40%	47.20%	45.80%	43.20%	39.80%
Qwen2.5-Coder-1.5B	26.40%	22.60%	23.00%	22.20%	22.40%
DeepSeek	68.20%	64.80%	65.00%	61.80%	63.60%

随机列总体影响温和，且非严格单调。需要注意，该条件同时加入了新表， 因此不能把曲线解释为“无关列数”的纯效应。

6.2 合成近义列

模型	base	5 列	10 列	20 列	50 列
Qwen3-0.6B	14.60%	7.00%	6.40%	5.20%	4.20%
Qwen3-1.7B	27.20%	14.20%	11.20%	11.40%	9.20%
Qwen3-4B	50.40%	19.40%	17.00%	18.00%	18.80%
Qwen2.5-Coder-1.5B	26.40%	18.20%	15.60%	13.60%	15.00%
DeepSeek	68.20%	30.00%	25.40%	27.60%	27.00%

5 列断崖需要按 `same_name` 分层解释。`add_synonym_5` 内部：

`same_name` 数	n	Qwen3-4B	DeepSeek
0	86	59.30%	74.42%
2	62	8.06%	25.81%
3	105	10.48%	16.19%
4	74	20.27%	29.73%
5	170	8.82%	18.24%

同样加入 5 列，没有 `same_name` 时 Qwen3-4B 仍有 59.3%；一旦出现 2 个以上 同名干扰就掉到 8–20%。因此断崖主要由**同名跨表干扰**造成，而不是纯词法 近义。

6.3 原预注册执行门槛

模型	随机 20 列下降差	随机 95% CI	近义 20 列下降差	通过
Qwen3-0.6B	−1.80 pp	[−5.80, +2.00]	−31.20 pp	False
Qwen2.5-Coder-1.5B	−2.20 pp	[−7.00, +2.60]	−27.80 pp	False
Qwen3-1.7B	−1.00 pp	[−5.40, +3.40]	−24.80 pp	False
Qwen3-4B	+0.80 pp	[−3.60, +5.20]	−8.20 pp	False

四个随机 20 列差值的 CI 上界最高 +5.2pp。因此可以精确表述为： **数据可以排除“小模型多下降 10pp”的效应**，而不只是“未达到 10pp”。

6.4 Baseline-correct 条件分析

模型	共同正确题数	随机列额外失败	95% CI	近义列额外失败	95% CI
Qwen3-0.6B	69	+31.88 pp	[+18.84, +43.48]	+36.23 pp	[+24.64, +47.83]
Qwen2.5-Coder-1.5B	116	+34.48 pp	[+24.14, +44.83]	+10.34 pp	[+0.00, +20.69]
Qwen3-1.7B	127	+25.98 pp	[+17.32, +34.65]	+14.17 pp	[+6.30, +22.83]
Qwen3-4B	229	+12.23 pp	[+6.55, +17.90]	+6.11 pp	[+1.31, +11.35]

定义：额外失败率 = DeepSeek 在共同 base-correct 题上的扰动保持率 − 小模型在同一批题上的扰动保持率。正值表示小模型更脆弱。

该分析支持机制假设，但属于看到总体准确率后进行的条件分析，不能替代原 预注册门槛；它也忽略了“原本错、扰动后对”的增益。

6.5 真实 Schema 近义列敏感性

模型	base	合成近义列	真实近义列	合成下降	真实下降
Qwen3-0.6B	14.99%	6.09%	11.94%	8.90 pp	3.04 pp
Qwen3-1.7B	28.10%	12.41%	23.89%	15.69 pp	4.22 pp
Qwen3-4B	50.35%	17.80%	40.75%	32.55 pp	9.60 pp
Qwen2.5-Coder-1.5B	26.23%	13.58%	22.95%	12.65 pp	3.28 pp
DeepSeek	69.32%	28.10%	63.00%	41.22 pp	6.32 pp

但真实近义列条件也有表位置混淆：423/427 题引入新表，65.1% 的新增列在新表 里；只有 4 题是 gold_tables_only。因此“41.22pp → 6.32pp”不能全部归因于 “真实 vs 合成”，table placement 也变了。

6.6 纯列 20 补实验（v2）

只加列、不加表，五模型 base + pure 20。纯列补实验的 base 由同一次运行重新 生成，和 v1 base 可能有 0.2pp 左右的 GPU 推理波动；比较在本次运行内配对， 不跨运行混用。

模型	base	pure 20	下降	相对 DeepSeek 下降差	95% CI
Qwen3-0.6B	14.60%	9.60%	5.00pp	+0.60pp	[−3.00, +4.20]
Qwen3-1.7B	27.20%	18.20%	9.00pp	+4.60pp	[+0.20, +9.00]
Qwen3-4B	50.60%	44.40%	6.20pp	+1.80pp	[−2.40, +6.00]
Qwen2.5-Coder-1.5B	26.60%	26.00%	0.60pp	−3.80pp	[−8.20, +0.40]
DeepSeek	68.60%	64.20%	4.40pp	对照	–

全体准确率门槛仍不通过：四个 CI 上界都低于 10pp。但 baseline-correct 额外失败仍显著：Qwen3-0.6B +32.35pp [+20.59, +44.12]、 Qwen3-1.7B +34.13pp [+24.60, +43.65]、Qwen3-4B +10.00pp [+4.78, +15.65]、Coder +20.51pp [+11.97, +29.06]。

因此，原门槛失败不是“加表”造成的假象；在只加列、不加表的条件下，机制 仍然存在，但全体准确率门槛依然失败。

6.7 漏给条件

模型	条件	正确/可评测	普通准确率	base-correct 保持率	合规率（可评估子集）
Qwen3-0.6B	移除桥接表	0/103	0.00%	0.00%	0.00%（0/14）
Qwen3-0.6B	移除外键列	8/494	1.62%	12.20%	2.50%（2/80）
Qwen3-1.7B	移除桥接表	3/103	2.91%	10.00%	11.11%（3/27）
Qwen3-1.7B	移除外键列	37/494	7.49%	25.66%	3.82%（6/157）
Qwen3-4B	移除桥接表	3/103	2.91%	6.38%	5.66%（3/53）
Qwen3-4B	移除外键列	100/494	20.24%	38.66%	2.41%（8/332）
Qwen2.5-Coder-1.5B	移除桥接表	2/103	1.94%	14.29%	9.09%（2/22）
Qwen2.5-Coder-1.5B	移除外键列	50/494	10.12%	50.54%	1.26%（2/159）
DeepSeek	移除桥接表	20/103	19.42%	28.36%	11.11%（9/81）
DeepSeek	移除外键列	173/494	35.02%	50.92%	2.47%（11/446）

关键修正：

- “合规率”的分母是 authorizer 成功执行合规分析的子集 （`compliance_evaluated`），不是全部变体，也不是 base-correct。 因此不能直接跨模型比较，也不能把它写成“合规准确率”而不注明分母。
- `SELECT *` 不是主要问题：五个模型合计只有 0–6 条预测使用 `SELECT *`。
- evidence 泄漏需要处理：40/494 外键变体、9/103 桥接变体的 evidence 中 出现被移除名字。剔除后外键普通准确率：DeepSeek 33.26%（原 35.02%）、 Qwen3-4B 18.06%（原 20.24%）、Qwen3-1.7B 7.27%、Qwen0.6B 1.54%。
- 普通准确率高估的是“合规恢复能力”，不是“任务结果恢复”。猜中隐藏列 在 outcome 上也是一种恢复；论文中应区分 outcome robustness 与 process compliance。

7 讨论

- **扰动类型比列数更重要。** 随机加表/加列影响温和；同名干扰在 5 列时 就造成断崖；纯列 20 只造成 0.6–9.0pp 的总体下降。
- **全体准确率门槛受 baseline floor effect 影响。** Qwen3-0.6B baseline 14.60%，绝对下降空间有限；原 10pp 门槛存在结构性偏向。
- **Baseline-correct 分析显示机制存在。** 小模型在原本会做的题上对 schema 干扰更脆弱；纯列 20 复现了这一点（+10.00 到 +34.13pp）。
- **检索偏差是外键/join 列，不是桥接表。** 控制多表题后，桥接表内列不再 更难；这与“连接键在向量空间中缺少语义”的解释一致。
- **合成近义列是强干扰，但不是真实 schema 的代表。** 5 列断崖主要来自 `same_name`；真实近义列条件又混入了新表，不能单独归因于词法真实性。
- **漏给结果支持“连接 schema 成分缺失会造成严重退化”，但不支持“大模型 能在完全不使用缺失成分时稳定恢复”的强结论。**

- **RQ3 仍未识别。** 原执行实验使用 oracle schema；检索偏差是独立测量。 若要检验“检索漏选导致执行失败”，需要 retrieved-schema 执行条件。

8 有效性与局限

维度	风险或限制	当前处理
内部效度	baseline floor effect	报告主门槛失败，并补充 baseline-correct
内部效度	`add_random_*` 同时加表	v2 增加纯列条件；原始条件改称“跨表扩展”
构念效度	合成近义列含大量 `same_name`	按 `same_name` 分层；5 列断崖改写
构念效度	真实近义列仍主要加新表	报告 423/427 与 4 题 gold-only；不做强归因
统计效度	gate 原代码未对齐 qid	v2 已按 question_id 对齐；CI 上界 <10pp
统计效度	单次 greedy 推理	固定模型与 prompt；报告 bootstrap CI
评测效度	官方 30 秒超时和重复行规则	严格采用官方 set 语义
构念效度	schema 隐藏但数据库保留列	authorizer 检查读取对象，报告普通/合规两种口径
构念效度	合规分母是 authorizer 子集	明确标注 `compliance_evaluated`
构念效度	evidence 可能泄漏被移除名字	报告泄漏数并做剔除敏感性分析
外部效度	仅一个 Mini-Dev 数据集	下一步 Spider 2.0-Lite
外部效度	检索仅一个 MiniLM、两种 query	结论限定为当前 setup；不外推到所有 retriever
可复现性	DeepSeek API 版本可能变化	记录模型别名和调用日期
完整性	桥接移除子集 base 正确数很低	报告地板效应和题目聚类 CI

9 结论与决策

判定项	结论
检索桥接成分漏选显著更高（原指标）	通过
控制多表题后桥接表内列更难	不成立（-13.91pp）
外键/join 列更难召回	成立（+13.75pp）
小模型全体执行准确率下降比 DeepSeek 多 10pp	不通过；CI 可排除 +10pp
Baseline-correct 机制证据	支持假设，但为事后分析
纯列 20 全体门槛	不通过；CI 上界 <10pp
纯列 20 baseline-correct	支持机制（+10.00 到 +34.13pp）
真实 schema 近义列敏感性	支持机制，但受 table placement 混淆
漏给普通执行准确率	DeepSeek 明显更高，小模型接近地板
漏给合规恢复能力	五个模型均很低；大模型优势主要来自猜测隐藏列

严格结论：BIRD Mini-Dev 上的原预注册执行门槛没有通过，因此不能直接宣称 小模型在无关列下显著比大模型更脆弱。机制结论：在 baseline 可解问题、 纯列 20 和真实 schema 近义列条件下，小模型保持率显著更低，说明 schema linking 稳健性仍是一个可信的机制解释。漏给条件下，DeepSeek 的优势主要 来自读取或恢复被隐藏的连接列；当要求严格合规时，该优势基本消失。

决策：按照原计划，不基于 BIRD 结果直接确认完整研究假设；进入 Spider 2.0-Lite SQLite，使用预先固定的 baseline-correct 主指标复验。

10 Spider 2.0-Lite 下一步

- 下载并验证 Spider 2.0-Lite SQLite 数据、gold SQL 和数据库路径。
- 只用真实 schema 列构造 add_random_20 和 add_real_synonym_20。
- 固定 prompt、解码、最大输出长度、SQLite 超时和模型版本。
- 先做功效分析，不要直接把 50 题预实验当作主检验。
- 主指标：共同 base-correct 题上，小模型扰动保持率比 DeepSeek 低至少 10pp，且按问题聚类的 95% CI 下界大于 0。
- 若复验失败，按预案将论文重心收缩到 RQ1 的系统实证研究。

按 BIRD 上各模型与 DeepSeek 的 base 准确率、并假设题目间独立粗略推算， 共同 base-correct 的期望题数为：

模型	base acc	50 题	135 题
Qwen3-0.6B	14.60%	5.0	13.4
Qwen3-1.7B	27.20%	9.3	25.0
Qwen3-4B	50.40%	17.2	46.4
Qwen2.5-Coder-1.5B	26.40%	9.0	24.3

50 题和 135 题都达不到“每个模型共同 base-correct ⩾30”的预实验门槛； 0.6B 需要约 300 题。Spider 前应先做功效分析，或从确认性门槛中去掉 0.6B。

附录：实验产物

服务器正式目录：`/root/fsas/home/xiaotao/xiaotao/MINIDEV/BIRD_RESULTS`。
本地同步目录：`7-8周/BIRD_RESULTS/`。
本地事后审计报告：`result/POSTHOC_REANALYSIS_2026-10-22.md/.docx`。

主要产物：

- `BIRD_RESULTS/predictions_pure_column/`：五模型 × 1,000 条纯列补实验预测。
- `BIRD_RESULTS/scores_official_pure_column/`：官方 set 语义评分。
- `BIRD_RESULTS/analysis/reanalysis/`：原官方分数的 qid 对齐 gate、 transition、synonym/random/real-synonym 分层。
- `BIRD_RESULTS/analysis/reanalysis_pure_column/`：纯列 20 gate 与 baseline-correct。
- `BIRD_RESULTS/analysis/retrieval_matched_exact/`：原始检索 setup 的 匹配基线。
- `BIRD_RESULTS/analysis/retrieval_matched_exact_qe/`：question+evidence 版本。
- `BIRD_RESULTS/analysis/missing_compliance/`：authorizer 合规审计。
- `BIRD_RESULTS/scripts/`：服务器实际使用的 official scorer 与分析脚本。
- `BIRD_RESULTS/logs/pure_column/`：生成与评分日志。

复现命令见 `analysis/README.md`。