BIRD Mini-Dev 验证性实验两页报告

小模型 Schema 鲁棒性与向量检索桥接偏差

实验日期：2026 年 10 月 21 日
数据：BIRD Mini-Dev SQLite，500 题，11 个数据库
模型：Qwen3-0.6B/1.7B/4B、Qwen2.5-Coder-1.5B、DeepSeek API

1 验证目的与通过标准

验证小模型相对于 API 大模型是否更容易受到 schema 多给与漏给的影响，并检查向量检索是否系统性漏掉跨表连接所需成分。原任务书通过标准要求：小模型在多给 20 列时的准确率下降比 DeepSeek 多至少 10 pp，且桥接成分漏选率显著高于普通列。

2 实验规模与执行

实验块	覆盖范围	状态
多给扰动	base + random/synonym × 5/10/20/50，每模型 4,500 条	已完成
真实近义列	427 题 × 5 模型，共 2,135 条	已完成
漏给扰动	桥接表 103 + 外键列 494，每模型 597 条	已完成
检索偏差	500 题，k=5/10/20/50，问题聚类 bootstrap	已完成
执行评分	五模型 SQLite 执行，官方 set 语义，30 秒超时	已完成

3 关键结果

3.1 检索门槛：通过

指标	漏选率	相对单表目标列
单表目标列	28.71%	参照
桥接表内列	41.60%	+12.89 pp
外键/关键连接列	57.85%	+29.14 pp
桥接成分并集	56.88%	+28.17 pp [+20.58, +35.65]

3.2 多给 20 列执行门槛：未通过

模型	随机 20 列准确率	下降差（小模型−DeepSeek）	近义 20 列下降差	通过
Qwen3-0.6B	10.00%	−1.80 pp	−31.20 pp	否
Qwen3-1.7B	21.80%	−1.00 pp	−24.80 pp	否
Qwen3-4B	43.20%	+0.80 pp	−8.20 pp	否
Qwen2.5-Coder-1.5B	22.20%	−2.20 pp	−27.80 pp	否

四个小模型的随机 20 列下降差均未达到 +10 pp。全体准确率比较受 baseline floor effect 影响，因此补充了双方 base 都正确的条件分析：随机 20 列额外失败分别为 31.88、34.48、25.98、12.23 pp，四个 95% CI 下界均大于 0。该结果支持机制假设，但属于事后分析，不能替代原预注册门槛。

3.3 漏给条件：普通准确率高估恢复能力

模型	桥接普通	桥接合规	外键普通	外键合规
Qwen3-0.6B	0.00%	0.00%	1.62%	2.50%
Qwen3-1.7B	2.91%	11.11%	7.49%	3.82%
Qwen3-4B	2.91%	5.66%	20.24%	2.41%
Qwen2.5-Coder-1.5B	1.94%	9.09%	10.12%	1.26%
DeepSeek	19.42%	11.11%	35.02%	2.47%

移除桥接表后结果接近地板。移除外键列后，DeepSeek 普通准确率为 35.02%，但其 173 条正确预测中有 162 条仍读取已从 schema 移除的列；Qwen3-4B 为 92/100。严格要求预测不使用被移除对象后，四个本地模型的外键合规准确率为 1.26%–3.82%。因此普通执行优势主要来自恢复或猜中隐藏连接列。

4 综合结论

- 检索门槛通过：桥接成分并集漏选率显著高于单表目标列，差值为 +28.17 pp，95% CI [20.58, 35.65]。
- 原预注册执行门槛未通过：四个小模型在随机多给 20 列时均未比 DeepSeek 多下降 10 pp。
- Baseline-correct 与真实近义列分析支持机制假设，但这些都是事后补充，不能改写主门槛结论。
- 漏给实验完成并提供了机制证据：连接成分缺失会造成严重退化，但大模型的普通优势主要依赖读取隐藏连接列。
- 因此，BIRD 结果足以支撑 RQ1 的系统实证，但不能确认“小模型全体准确率下降比大模型多 10 pp”的原操作化假设。

5 Spider2-Lite 回退实验的数据阻塞

任务书计划在 Spider2-Lite SQLite 135 题上重复验证。题目、135 个表级 gold 和官方执行结果均已具备，但列级标签不完整：官方公开 24 条 Lite gold SQL；补充同题同表的 Snow gold SQL 后仅覆盖 50 题。

项目	数量	状态
Spider2-Lite SQLite 题	135	已具备
SQLite 数据库与映射	30 个库 / 135 条映射	已具备
表级 gold 与结果 CSV	135	已具备
Lite 原生 gold SQL	24	已公开
加入同题 Snow SQL 后覆盖	50	可用于预实验
仍缺列级 gold SQL	85	需要决策

剩余 85 题包含 60 道多表题、25 道单表题和 8 道依赖外部知识文档的题。没有 gold SQL 就无法可靠恢复标准答案所需列，也无法构造与原计划等价的列级多给、漏给和桥接检索标签。

6 导师需要确认的下一步

方案	做法	评价
A 官方 50 题	先跑五模型 base-only，再跑 20 列扰动	可立即执行，但样本仅 50
B 重建 85 题	独立模型/人工写 SQL，官方结果验证，冻结列标签	可达到 135，但工作量大且非官方
C 表级 135 题	以 gold tables 全部列为 baseline	无需缺失 SQL，但研究变量改变
D 收缩 RQ1	以 BIRD 与可用的 Spider2 结果做系统实证	符合任务书兜底，风险最低

建议先执行方案 A 的 base-only 预实验，同时向 Spider2 作者申请剩余 gold SQL 或 gold columns。只有在五模型共同 base-correct 达到 30 题且导师认可重建标签后，才投入剩余 85 题。不要在看到模型结果后挑选容易题。

7 当前判定与请求

判定项	结论
BIRD 验证实验执行	已完成，结果可复现
检索桥接偏差	通过
多给 20 列 10 pp 主门槛	不通过
RQ1 系统实证价值	成立，机制证据存在
Spider2-Lite 135 题列级实验	受 85 条标签缺失阻塞
当前请求	导师确认 A/B/C/D 中的回退方案

详细总报告：outputs/BIRD-Experiment/BIRD_MiniDev_Experiment_Report.pdf。全部预测、评分、脚本与审计文件位于服务器 MINIDEV/BIRD_RESULTS。

8 事后补充（2026-10-22）

- 纯列 20 补实验（只加列、不加表）已完成：全体准确率门槛仍不通过 （四个下降差 +0.60/+4.60/+1.80/-3.80pp，CI 上界均 <10pp）； baseline-correct 额外失败仍为 +32.35/+34.13/+20.51/+10.00pp。
- 检索匹配基线：控制多表题后，桥接表内列不再更难（-13.91pp）， 外键/join 列仍显著更难（+13.75pp）。
- 5 列近义断崖主要由 `same_name` 造成：`same_name=0` 时 Qwen3-4B/ DeepSeek 为 59.30%/74.42%，出现 2 个以上同名干扰后降至 8–20%。
- 详见 `result/POSTHOC_REANALYSIS_2026-10-22.md`。