BIRD Mini-Dev 事后重分析

日期：2026-10-22
对象：`BIRD_MiniDev_Experiment_Report` 与原始扰动/评分文件
性质：不重跑模型的事后重分析；不改变原报告已记录的预注册判定。
本地结果副本：`7-8周/BIRD_RESULTS/`（预测、官方评分、分析 JSON、日志）。

结论摘要

1. 原“桥接成分”检索结论需要收窄：在控制“多表题”这一因素后，桥接表内列并不比多表题的非桥接目标列更难召回；显著更难的只有外键/join 列。
2. 原 `add_random_*` 条件同时加入了新表，不能解释为“无关列”效应。
3. 原 `add_synonym_5` 主要是 `same_name` 列，不是纯词法近义列；“5 列断崖”需要按 `relation` 分层重写。
4. 原执行门槛的代码存在配对对齐问题；修复后结论方向不变，但应把“未达到 10pp”写成“数据可以排除 +10pp”。
5. 原缺失 schema 实验的“合规准确率”分母是 authorizer 成功子集；需改标签，并检查 `SELECT *` 与 evidence 泄漏。
6. 纯列 20 补实验已完成：全体准确率门槛仍不通过，但 baseline-correct 额外失败仍显著；原门槛失败不是“加表”造成的假象。

1. 检索：+28.17pp 主要是多表题难度，其次是外键列

原报告用“单表目标列”作基线，但桥接成分只出现在多表题。重分析加入 `multi_nonbridge`：多表题中既不属于桥接表、也不属于 join/FK 的目标列。使用相同的 `all-MiniLM-L6-v2`、question-only、`table.column` 文档，k=10：

类别	漏选率
单表目标列	28.71%
多表题非桥接目标列	47.45%
桥接表内列	41.60%
外键/join 列	57.85%
桥接成分并集	56.88%

按问题配对的 bootstrap（k=10）：

比较	差值	95% CI
桥接表内列 − 多表非桥接目标列	−13.91 pp	[−24.22, −3.69] pp
外键列 − 多表非桥接目标列	+13.75 pp	[+9.79, +17.73] pp
桥接成分并集 − 多表非桥接目标列	+13.11 pp	[+9.16, +17.14] pp

解读：原报告“桥接成分并集比单表目标列高 28.17pp”把题目类型效应和列类型效应混在一起；控制多表题后，桥接表内列反而比非桥接目标列更容易召回（−13.91pp），外键/join 列仍显著更难（+13.75pp）。

该结果由服务器上的原脚本 `evaluate_retrieval_bias.py` 的文档构造与标签 集合重算，绝对漏选率与原报告完全一致（单表 28.71%、桥接表内列 41.60%、 外键 57.85%、并集 56.88%）。本地另一套 `table.column` 复算方向一致， 但绝对数值不同，不作为主结果。

question+evidence 条件下，原报告绝对值为单表 20.57%、桥接表内列 43.60%、 外键 58.97%、并集 57.66%。匹配基线结果为：桥接表内列 − 多表非桥接目标列 **+2.15pp**，95% CI [−7.96, +12.24]（不显著）；外键列 **+26.11pp**， 95% CI [+22.15, +30.16]。也就是说，桥接表本身的偏差会随 query 变化，外键/join 列的偏差在两种 query 下都稳健。

2. random 条件实际加了新表

从 `perturbations/output/mini_dev_perturbations.jsonl` 直接统计：

条件	至少新增一张表	新增列来自新表
`add_random_5`	467 / 500	63.8%
`add_random_10`	488 / 500	62.1%
`add_random_20`	494 / 500	58.9%
`add_random_50`	496 / 500	51.2%

`add_random_50` 平均新增约 5 张表，基本接近整库 schema。原报告“随机列影响 温和”应改写为“额外表影响温和”；它不能回答“只加无关列会怎样”。

3. synonym 条件不是纯近义列

`add_synonym_*` 的新增列构成：

条件	`same_name`	`synonym`	`same_name` 占比
5 列	1588	912	63.5%
10 列	1993	3007	39.9%
20 列	2168	7832	21.7%
50 列	2181	22819	8.7%

5 列的断崖主要是同名跨表列/同表近名，而不是词法近义。按 `add_synonym_5` 内部再分层（Qwen3-4B / DeepSeek）：

`same_name` 数	n	Qwen3-4B	DeepSeek
0	86	59.30%	74.42%
2	62	8.06%	25.81%
3	105	10.48%	16.19%
4	74	20.27%	29.73%
5	170	8.82%	18.24%

同样加入 5 列，没有 `same_name` 时 Qwen3-4B 仍有 59.3%，一旦出现 2 个以上 同名干扰就掉到 8–20%。因此“近义列 5 列断崖”应改写为“同名跨表干扰造成 断崖；纯词法近义的影响小得多”。

真实 schema 条件也存在表位置混淆：423/427 题引入新表，65.1% 的新增列在 新表里；合成条件则全部加在 base tables。因此“41.22pp → 6.32pp”不能全部 归因于“真实 vs 合成”。

4. 执行门槛代码修复

原 `analyze_execution_gate.py` 计算了 `common_ids` 却没有使用，bootstrap 直接 截断两个列表；若某条件有缺失记录，配对会错位。已修复为按 `question_id` 对齐，并新增：

- `p_one_sided_10pp`：检验“差值 ⩽ 10pp”；
- `excludes_10pp_gap`：95% CI 上界是否低于 10pp；
- `passed_strict_10pp_ci`：95% CI 下界是否达到 10pp。

原报告四个随机 20 列差值的 95% CI 上界最高为 +5.2pp，因此在修复后仍可 更精确地写：**数据可以排除“小模型多下降 10pp”这一效应**，而不是仅说 “样本不够/未达到”。

5. baseline-correct 的定位

baseline-correct 是“双方 base 都正确”的条件子集分析，属于事后分析； 它忽略了“base 错、扰动后对”的增益。建议补 2×2 transition matrix，并把 estimand 写成条件效应；不要把它称为“机制证明”。它仍可作为进入 Spider 预注册主指标的依据。

6. 缺失 schema 实验的口径

- `合规准确率` 的分母既不是全部 103/494，也不是 base-correct，而是 **authorizer 成功执行合规分析的子集**（`compliance_evaluated`）。 DeepSeek bridge 为 9/81=11.11%，FK 为 11/446=2.47%；Qwen3-1.7B bridge 为 3/27=11.11%。因此该列应改名为 “合规可评估子集上的合规率”，不能直接跨模型比较——各模型 `compliance_evaluated` 差异很大（如 bridge：Qwen0.6B 14，DeepSeek 81）。 若按全部变体作分母，DeepSeek bridge 为 9/103=8.74%，FK 为 11/494=2.23%。
- `SELECT *` 不是主要问题：五个模型合计只有 0–6 条预测使用 `SELECT *`。
- evidence 泄漏需要处理：40/494 外键变体、9/103 桥接变体的 evidence 中出现 被移除名字；在正确预测中，DeepSeek 外键有 22 条、Qwen3-4B 有 18 条 同时命中 evidence 泄漏。剔除这些变体后，外键普通准确率为： DeepSeek 33.26%（原 35.02%）、Qwen3-4B 18.06%（原 20.24%）、 Qwen3-1.7B 7.27%（原 7.49%）、Qwen0.6B 1.54%（原 1.62%）。 泄漏变体本身准确率更高（如 Qwen3-4B 45.0%），但不改变主结论； 论文中应把剔除版本作为敏感性分析。
- “普通准确率高估恢复能力”只对“不使用隐藏信息的合规恢复”成立； 对“任务结果恢复”而言，猜中隐藏列也是一种恢复。论文中应区分 outcome robustness 与 process compliance。

7. 仍然成立的结论

- 原预注册执行门槛不通过；不能宣称原操作化假设得到确认。
- 随机/近义扰动确实会造成退化，但退化的来源需要按新增表、`same_name`、 `synonym` 重新归因。
- 检索对外键/join 列的偏差稳健；桥接表本身的偏差不稳健。
- 缺失连接成分会造成严重退化；合规恢复在五个模型上都很低。
- BIRD 结果足以支撑 RQ1 的系统实证，但不足以支撑“检索漏选 → 执行失败” 的因果中介结论。

8. 最小补实验：纯列 20 已跑完

新增 `perturbations/generate_pure_column.py`，生成只从 gold tables 采列的 `add_pure_column_20`（5/10/20 也已生成）。20 列条件中约 66.9% 是真实列， 33.1% 是中性 filler；5 列条件约 90% 是真实列。服务器上五个模型已跑完 `base` + `add_pure_column_20`，官方 set 语义评分结果如下：

模型	base	pure 20	下降	相对 DeepSeek 的下降差	95% CI
Qwen3-0.6B	14.60%	9.60%	5.00pp	+0.60pp	[−3.00, +4.20]
Qwen3-1.7B	27.20%	18.20%	9.00pp	+4.60pp	[+0.20, +9.00]
Qwen3-4B	50.60%	44.40%	6.20pp	+1.80pp	[−2.40, +6.00]
Qwen2.5-Coder-1.5B	26.60%	26.00%	0.60pp	−3.80pp	[−8.20, +0.40]
DeepSeek	68.60%	64.20%	4.40pp	对照	–

全体准确率门槛仍不通过：四个模型的 95% CI 上界都低于 10pp。但 baseline-correct 额外失败仍显著：Qwen3-0.6B +32.35pp [+20.59, +44.12]、Qwen3-1.7B +34.13pp [+24.60, +43.65]、 Qwen3-4B +10.00pp [+4.78, +15.65]、Coder +20.51pp [+11.97, +29.06]。因此，原门槛失败不是“加表”造成的假象；在只加列、 不加表的条件下，机制仍然存在，但全体准确率门槛依然失败。

这补的是原 RQ1 的核心操纵，不需要重跑原始 27,620 条预测。若 RQ3 要立住， 再补 retrieved-schema 执行条件：`perturbations/generate_retrieved_schema.py` 可生成 top-10 检索 schema 变体（500 条，gold column recall 均值 54.6%）， 运行命令见 `analysis/README.md`。

9. Spider 样本量提醒

按 BIRD 上各模型与 DeepSeek 的 base 准确率、并假设题目间独立粗略推算， 共同 base-correct 的期望题数为：

模型	base acc	50 题	135 题
Qwen3-0.6B	14.60%	5.0	13.4
Qwen3-1.7B	27.20%	9.3	25.0
Qwen3-4B	50.40%	17.2	46.4
Qwen2.5-Coder-1.5B	26.40%	9.0	24.3

50 题和 135 题都达不到“每个模型共同 base-correct ⩾30”的预实验门槛； 0.6B 需要约 300 题。Spider 前应先做功效分析，或从确认性门槛中去掉 0.6B， 不要把 50 题预实验当作主检验。