第5–6周文献精读对比与重排基线报告

面向小模型数据智能体的表与列选择

实验日期：2026 年 10 月 21 日

0 本周验收结论

文件层面的两项交付已经齐备：七篇必读论文的对比表初稿，以及 Cross-Encoder 与 GRAST-SQL Qwen End-to-End 两个列重排基线结果表。任务书要求本人能够在组会上逐篇讲解论文、逐段解释代码，这部分仍需人工完成。

1 领域脉络与本课题定位

- BIRD 与 Spider 2.0 说明真实数据库的规模、脏值、外部知识和工作流复杂度已远超经典 Text-to-SQL；本课题不更换 parser，而是控制送给 parser 的 schema。
- The Death of Schema Linking? 表明强模型在完整 schema 可放入上下文时可能不需要 linking；但这一结论不能自动外推到 0.6B–4B 小模型和有限 token 预算。
- RSL-SQL、AttnLink 分别代表双向高召回 linking 和基于模型注意力的连续打分；它们的共同缺口是很少把目标小模型的边际效用、token 成本和连接图补全联合建模。
- SLM-SQL 与 MSc-SQL 表明小模型可通过后训练、多候选生成和 critique 大幅提升；本课题的 schema selector 位于生成之前，与它们互补，而不是替代关系。

2 七篇必读论文对比表

任务书第六项同时列出 SLM-SQL 与 MSc-SQL，本报告拆成两篇，因此表中实际有七篇。

论文	问题	方法	数据/实验	主要结果	基线	弱点	与本课题区别	用途
BIRD (NeurIPS 2023 D&B, arXiv:2305.03111)	真实数据库中脏值、外部知识和 SQL 效率未被已有 Text-to-SQL 基准覆盖。	提出大规模跨域基准，强调数据库值理解、evidence grounding 和效率，定义 EX/VES。	12,751 个问题-SQL 对，95 个数据库，33.4 GB；dev 1,534 条，Mini-Dev 500 条。	GPT-4 54.89% EX，人类 92.96%；说明真实大库仍远未解决。	T5 fine-tuning、ChatGPT、Claude-2、GPT-4；GPT-4 54.89% EX，人类 92.96%。	标注成本高，以 SQLite 为主，没有单独控制系统仍需要多少 schema，也未解决大 schema 的 token 预算。	本课题不提出新 parser，而是使用 BIRD 研究小模型在多给/漏给 schema 条件下的敏感性，并将 BIRD 作为主数据和机制实验平台。	主数据集与 RQ1 证据来源
Spider 2.0 (ICLR 2025, arXiv:2411.07763)	企业级工作流包含超大 schema、多 SQL 方言、项目代码库和多步数据库操作。	提出 632 个企业级任务及 agent 评测框架，并提供自包含的 Lite/Snow Text-to-SQL 子集。	632 个任务，平均 812 列；Lite 547 条，其中 SQLite 135 条。	o1-preview 代码 agent 仅解决 21.3%，而 Spider 1.0 为 91.2%、BIRD 为 73.0%。	代码 agent 和 Text-to-SQL 模型；o1-preview agent 在 Spider 2.0 仅解决 21.3%，Spider 1.0 为 91.2%。	完整任务依赖代码库、云数据库和昂贵交互；公开 gold SQL 不完整，难以直接做严格列级监督。	本课题只使用 Lite SQLite 子集，刻意隔离大 schema 选择问题，不使用多步 agent，也不把云数据库成本引入验证实验。	大 schema 外部效度数据
The Death of Schema Linking? (arXiv:2408.07702)	schema linking 可能漏掉必需列，但强模型是否仍需要先做 schema linking？	比较全 schema 与不同 precision/recall 的 linking；采用 augmentation、selection、correction，并迭代 fine-tune GPT-4o。	BIRD；按数据库抽取 dev 10% 作为评测，训练样本 500；报告 BIRD 71.83% EX。	在完整 schema 可放入上下文时，ft:GPT-4o pipeline 达到 BIRD 71.83% EX。	GPT-4o、GPT-4o-Mini、GPT-4-Turbo、Llama 3.1、DeepSeek Coder、Claude 3.5、Gemini 1.5 等 12 个模型。	核心结论限定在完整 schema 能放入上下文的强模型；没有系统研究 0.6B–4B、小 token 预算和桥接结构补全。	本课题直接检验小模型是否需要更保守的 schema selection，并把 token 成本、模型感知效价和连接图补全列为核心变量。	反方观点与 RQ1 动机
RSL-SQL (arXiv:2411.00073)	schema linking 一方面减少噪声，另一方面可能漏掉必需列并破坏数据库结构完整性。	双向 schema linking、上下文增强、完整/简化 schema 双路生成与二选一、多轮自纠错。	BIRD、Spider；GPT-4o 与 DeepSeek；strict recall 94%，平均输入列减少 83%。	GPT-4o 在 BIRD 67.21% EX、Spider 87.9% EX；严格 schema recall 94%。	DIN-SQL、DAIL-SQL、MAC-SQL、TA-SQL、E-SQL 等开源 Text-to-SQL 方法。	依赖复杂 prompt 流程和大模型生成能力；目标是高召回而非显式 token 预算，未学习下游小模型的边际效用。	本课题在固定 token 预算下预测目标小模型的边际收益，显式权衡 false positive 与 false negative，并用主外键图补全桥接成分。	强 schema-linking 基线与 RQ3 对照
SLM-SQL (arXiv:2507.22478)	0.5B–1.5B 小模型受逻辑推理能力限制，在 Text-to-SQL 上明显落后。	基于 SynSQL-2.5M 构造 Think/Merge 数据，使用 SFT、RL 和 Corrective Self-Consistency 进行后训练与推理。	BIRD 与 Spider；Qwen2.5-Coder-0.5B/1.5B、Qwen3-0.6B、Llama-3.2-1B、DeepSeek-Coder-1.3B。	BIRD dev：0.5B 56.87%、Qwen3-0.6B 59.52%、1.5B 67.08% EX。	原始模型、SFT、SFT+RL、CSC-SQL；BIRD 上 0.5B 56.87% EX，1.5B 67.08% EX。	明确不研究 schema linking、agent 或 pipeline；依赖大规模后训练与多次候选推理。	本课题不修改模型权重，而是在模型前处理阶段选择 schema；两者互补，可用 SLM-SQL checkpoint 检验 schema selector 的跨模型迁移。	小模型能力上界与模型族依据
MSc-SQL (NAACL 2025, arXiv:2410.12916)	小型开源模型单独生成 SQL 仍落后于 GPT-4，同时 API 模型存在隐私、延迟和成本问题。	采样多个候选 SQL，训练 critique model 同时比较 SQL、执行结果和元数据，选择最佳候选。	BIRD 与 Spider；10B 以下开源模型及同规模模型集成。	BIRD dev 65.6% EX，Spider test 84.7% EX，使用 7B/8B/9B 三个模型形成候选。	SFT 小模型、self-consistency、DTS-SQL、CodeS 及其他开源与闭源系统。	增加多候选采样和 critique 推理管线；核心优化发生在 SQL 生成之后，没有解决前端 schema 信息过多或缺失。	本课题作用于 SQL 生成前的 schema selection，目标是在 token 预算内提高目标模型生成正确 SQL 的概率，可与 MSc-SQL 的候选批评阶段级联。	小模型 test-time baseline

论文	问题	方法	数据/实验	主要结果	基线	弱点	与本课题区别	用途
AttnLink (arXiv:2608.00693)	现有 schema linking 在语义建模、连续分数可控性和推理效率之间做取舍。	从 LLM generation-anchor attention 提取 schema relevance；AttnLink-U 无训练，AttnLink-S 用 set-mass 与 adaptive floor 监督，支持 temperature/top-p。	Spider、BIRD、Spider2-SQLite；mAP 分别为 99.22%、95.95%、83.29%，并测试 9 组下游生成器设置。	Qwen3.5-9B AttnLink-S 的 schema-linking mAP 为 99.22/95.95/83.29；下游 EX 在 7/9 设置最佳或并列最佳。	embedding retriever、cross-encoder reranker、生成式 schema linker 和 attention probing 基线。	依赖白盒 LLM 的注意力、层/头选择和模型架构；主要输出相关性分数，没有直接学习特定小模型的 token 预算边际效用和描述粒度。	本课题以目标小模型的对数似然反馈训练模型感知效用预测器，并联合 token 预算、描述粒度和连接图补全；AttnLink 是直接强基线。	最新 schema-linking 强基线

3 逐篇对本课题的直接启示

BIRD：提供主实验数据和 external evidence；RQ1 必须在该 benchmark 上给出系统敏感性曲线，而不仅是检索指标。

Spider 2.0：证明大 schema 场景真实存在，但其公开 gold SQL 不完整；完整 135 题列级实验要先解决标签问题。

The Death of Schema Linking?：要求论文正面回答“强模型不需要 linking，小模型是否同样”。因此 RQ1 必须按模型大小分层，而不是只报平均。

RSL-SQL：其 strict recall 与完整/简化 schema 双路选择说明：漏选风险和误选风险必须同时报告；它也是 RQ2/RQ3 的强基线。

SLM-SQL：小模型后训练后绝对 EX 可以很高，因此 schema 选择实验不能只使用未微调模型；后续应至少加入一个 SLM-SQL checkpoint 做泛化检验。

MSc-SQL：多候选 critique 可以弥补小模型生成能力，但会增加 test-time compute；预算比较应同时计算 schema token 和候选采样成本。

AttnLink：给出最新高精度、低延迟 linking 基线；其模型内部注意力方案适合强 GPU 环境，但仍需与模型感知效价和连接图连通性比较。

4 重排基线实验设置

数据为 BIRD dev，共 1,534 道题；候选列 115,903 个，其中 gold 列 6,461 个。默认判定阈值为 0.0；Steiner 指标在原始候选集合上加入最小连通子图后处理。Cross-Encoder 为 encoder_only 模式；GRAST-SQL 为 Qwen End-to-End 模式。

4.1 核心指标

基线	ROC AUC	PR AUC	Raw P	Raw R	Raw F1	Steiner P	Steiner R	Steiner F1
Cross-Encoder	0.6237	0.0818	77.33%	26.08%	39.00%	77.20%	28.24%	41.35%
GRAST-SQL (Qwen End-to-End)	0.8622	0.4713	79.80%	47.14%	59.27%	78.42%	67.05%	72.29%

4.2 阈值、召回与效率

基线	最优 Raw F1	最优 Steiner F1	低召回样本	平均嵌入秒/样本	平均推理秒/样本
Cross-Encoder	34.85%	35.24%	1282/1534 (83.57%)	0.0000	0.1964
GRAST-SQL (Qwen End-to-End)	58.10%	70.58%	1355/1534 (88.33%)	0.2246	0.0100

5 基线结果解释与有效性限制

- ROC AUC 从 0.6237 提升至 0.8622，PR AUC 从 0.0818 提升至 0.4713，说明在当前候选集与打分协议下，GRAST-SQL 的列排序区分度明显更强。
- Steiner F1 从 41.35% 提升至 72.29%，Steiner recall 从 28.24% 提升至 67.05%；连接图后处理对多表 schema linking 有明显影响，因此后续必须单独报告 raw 与 Steiner 两套指标。
- GRAST-SQL 的低召回样本数反而更多（1,355 对 1,282），但其 Steiner recall 更高，说明 Cross-Encoder 的问题不是少量边界误差，而是更大范围的系统性漏检。
- Cross-Encoder 平均推理约 0.196 秒/样本；GRAST 嵌入约 0.225 秒、推理约 0.010 秒，端到端仍在同一数量级。该结果不能代表所有 checkpoint 或批量推理设置。
- 两项实验均为冻结模型评测，使用固定输入和确定性流程，没有进行训练，因此当前没有按三个训练种子报告均值/标准差。报告必须明确这一实验性质。
- 当前差距只证明本实验配置下的现象，不应写成 GRAST-SQL 普遍优于所有 Cross-Encoder；仍需核对 checkpoint、候选生成、分数校准和 Steiner 实现是否完全一致。

6 仍需人工完成

- 逐篇通读论文原文，核对本报告的摘要、方法、实验结果和局限，准备组会讲稿。
- 逐段解释 GRAST-SQL 和 Cross-Encoder 代码：候选生成、schema 序列化、打分、阈值、Steiner 补全、指标计算。
- 确认 GRAST-SQL 的 checkpoint、candidate pool、层/头设置，以及 Cross-Encoder 的实际模型和训练来源。
- 明确本实验是单次冻结模型评测；若导师要求三个种子，需要重新定义随机来源和运行矩阵。

7 结论

七篇论文共同说明：真实数据库需要 schema 选择，但现有方法主要在强模型或大规模 Text-to-SQL pipeline 上优化，缺少面向小模型、token 预算和桥接连通性的统一框架。本课题的 RQ1 现象验证具有独立价值，RSL-SQL 与 AttnLink 是最直接的 schema-linking 对照，SLM-SQL 与 MSc-SQL 说明模型后训练和生成后 critique 必须作为互补变量控制。当前两项重排基线已经跑通，但后续仍需完成个人精读、代码解释和组会验收。